

BUILD WITH AI · OPEN 2026 · LIMA

Más allá del texto

RAG Multimodal con Gemini y Firestore

Una exploración con comida peruana

presioná para empezar





QUIÉN SOY

Tomás Piaggio

 **Google Developer Expert** · Firebase

Trabajo con vector search y modelos de IA todos los días. Hoy les muestro lo que aprendí, usando algo que todos conocemos.

- embeddings
- rag
- multimodal
- firestore
- gemini

ESCENA 02

¿Qué son los embeddings?

¿Cómo le explico el sabor del ceviche a una máquina? Con números.

ceviche

Embebir

CEVICHE · 0 DIM

EL CÓDIGO QUE ESTÁ CORRIENDO

```
import { google } from '@lib/gemini'
import { embed } from 'ai'


const { embedding } = await embed({
  model: google.embedding('gemini-embedding-001'),
  value: 'ceviche',
})

// embedding.length === 768
```

ESCENA 03

¿Cómo funcionan y para qué sirven?

Cada plato es un punto. Los parecidos se agrupan.



DONDE YA LAS USÁS

Spotify

recomendaciones de canciones por gusto

Google

búsqueda semántica

ChatGPT

memoria de conversaciones largas

E-commerce

productos similares y recomendaciones

ESCENA 04

El problema con la búsqueda tradicional

comida reconfortante en día lluvioso...

Buscar

- ceviche
- comida reconfortante en día lluvioso
- algo dulce y cremoso
- plato típico de la sierra

BÚSQUEDA POR PALABRA CLAVE

sin resultados

BÚSQUEDA SEMÁNTICA

sin resultados

EL CÓDIGO QUE ESTÁ CORRIENDO

+



ESCENA 05

Embedding en vivo

Arrastrá un PDF de receta sobre el panel. Lo dividimos, lo embebemos y lo guardamos en Firestore acá mismo.



Arrastrá un PDF acá
o hacé click

- Leyendo el PDF
- Dividiendo en fragmentos
- Generando el embedding
- Escribiendo en Firestore

EL CÓDIGO QUE ESTÁ CORRIENDO

+

ESCENA 06

Reconoce la comida que ves

Cámara: Permission denied

RESULTADOS

EL CÓDIGO QUE ESTÁ CORRIENDO

+

ESCENA 07

¿Qué puedo cocinar?

Elegí ingredientes (la audiencia también puede sumar pidiendo en voz alta).

 pollo	 res	 chancho	 pescado	 camarones	 pulpo	 arroz	 papa
 yuca	 camote	 choclo	 frijol	 aji amarillo	 rocoto	 aji panca	 limón
 cebolla	 ajo	 tomate	 huevo	 queso fresco	 leche	 pan	 harina
 azúcar	 canela	 culantro	 huacatay	 maní	 quinua	 trigo	 chicha

Buscar platos (0)

EL CÓDIGO QUE ESTÁ CORRIENDO +


ESCENA 08

Pregúntale a la comida

Recuperación + generación = **RAG**. La respuesta sale únicamente de los platos recuperados.

Preguntar

- ¿Qué me conviene comer si estoy resfriado?
- Quiero algo picante con mariscos, ¿qué pido?
- Un postre cremoso para una celebración
- ¿Qué plato abriga en un día frío de sierra?



CONTEXTO RECUPERADO

Hacé una pregunta para recuperar platos.

RESPUESTA FUNDAMENTADA

La respuesta de Gemini aparecerá acá, citando los platos recuperados.



ESCENA 09

El mismo patrón, otro mundo

Música peruana. La misma forma de embebido aplica.

Buscar por mood

Grabar en vivo (instrumento)

Subir canción

paisajes andinos con zampoñas, instrumental y nostálgico

fiesta del pueblo con interacción de guitarra y charango

tristeza por un amor que se fue

EL CÓDIGO QUE ESTÁ CORRIENDO +

ESCENA 10

Lo que pasa por debajo

EL STACK

Stack

Next.js 16, React 19, TypeScript estricto, Tailwind v4, Framer Motion

SDK de AI

Vercel AI SDK (@ai-sdk/google 3.0.x sobre ai 6.x)

Modelos

gemini-embedding-001 (texto, 768d) · gemini-embedding-2 (multimodal, 1536d)

Vector DB

Firestore vectorField + findNearest, 100% en Firebase

Lo nuevo

Sólo el modelo nuevo y un providerOption nuevo. No hay SDK nuevo.

COSTOS

gemini-embedding-001\$0.00002 / 1k tokens

gemini-embedding-2\$0.0001 / request (orden de magnitud)

Firestore findNearestReads normales × k

Total estimado por consulta~\$0.0001 a \$0.0002

```
EL DIFF COMPLETO PARA SUMAR MULTIMODAL A UN STACK DE FIREBASE

const model = google.embedding('gemini-embedding-001')
// para multimodal:
const model = google.embedding('gemini-embedding-2')


await embed({
  model,
  value: '',
  providerOptions: {
    google: {
      outputDimensionality: 1536,
      content: [[{ inlineData: { mimeType, data } }]],
    },
  },
})
```



• • • • BUILD WITH AI · OPEN 2026 · LIMA

Sulpayki

El embedding ya aprendió el sabor del ceviche.
Lo que viene a continuación lo construyen ustedes.



Tomás Piaggio

Google Developer Expert · Firebase

[github.com/tpiaggio/rag-presentation](#) · [in/tomas-piaggio](#)

CONSTRUYAN ALGO · PREGÚNTENME · HABLEMOS

